Computació Paral·lela amb un clúster de Raspberry Pi. Programació amb Python i MPI.

Joan Gerard Camarena Estruch.

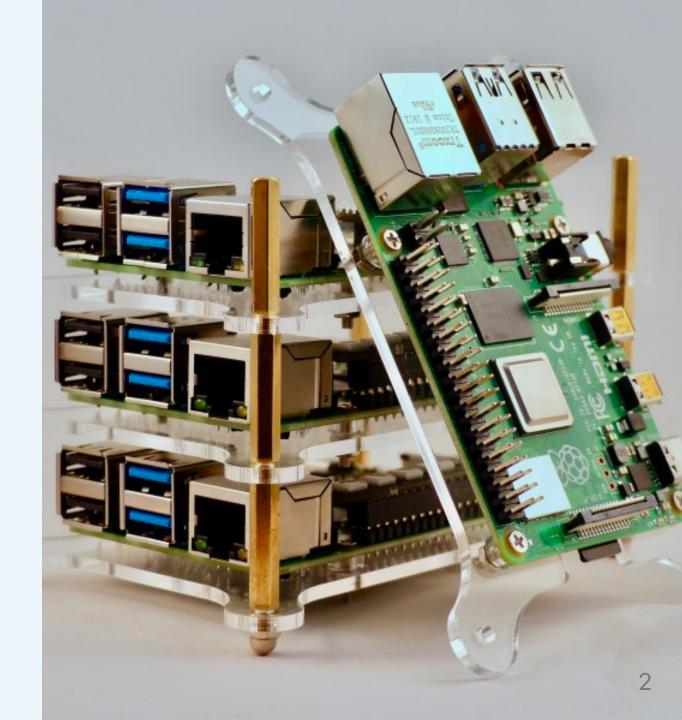
Elements necessaris

Hardware

- 4 raspberry Pi amb alimentador
- 4 microSD
- 1 Switch
- 1 rack per a Raspberry

Software:

- MPI (Message Passing Interface)
- Python
- ssh



Pla de treball

- 1. Acoblament del clúster
- 2. Instal·lar i configurar la imatge bàsica (master)
- 3. Copia i configuració de la resta d'imatges (nodes)
- 4. Configuració del clúster. Carpetes en xarxa. ssh i clusterssh
- 5. MPI (Message Passing Interface) Teoria i fonaments
- 6. Proves de programació distribuida

Acoblament del cluster

Teniu com a material:

- 4 rapsberrys Pi
- 4 carregadors
- 4 microSD
- 5 cables RJ45
- 1PC
- 1 rack
- 1 switc

Seguint les instruccions, atornillarem les plaquetes al rack i l'ensamblarem.

També hauriem de cablejar les raspberrys al switch

Imatge (1)

Descarregarem la imatge del sistema operatiu de la raspberry.

Donat que ho configurarem tot per ssh i la terminal, no necessitarem cap escriptori.

També aconseguim un menor consum de recursos.

La versió més actual és:

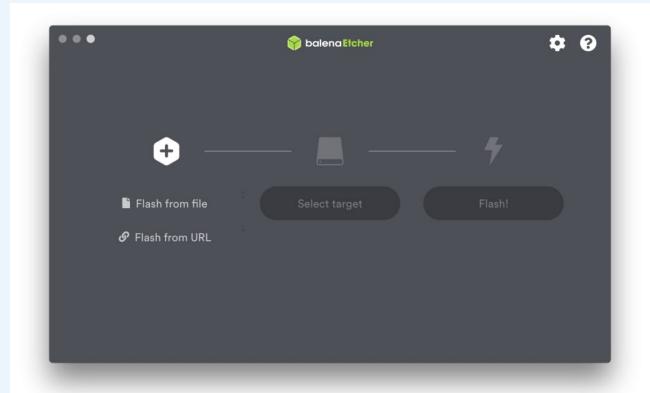
https://downloads.raspberrypi.org/raspios_lite_arm64/images/raspios_lite_arm64-2023-02-22/2023-02-21-raspios-bullseye-arm64-lite.img.xz

Nosaltres farem servir la verió de gener del 21, per millorar la compatibilitat.

Imatge (2)

El fitxer img resultant el tenim que escriure a una targeta microSD. Per a fer-ho podem fer servir distints programes:

- [Windows] → Win32ImageWriter, disponible en https://launchpad.net/win32image-writer
- [Ubuntu] → usb-imagewriter, dispoible als repositoris d'ubuntu
- Alternativa multiplataforma i recomanada balenaEtcher
 https://www.balena.io/etcher/ (sols grava a sd)



Imatge (3)

Des de la consola en sistemes **Linux/Mac**, tant per gravar com per clonar:

- 1. Executar sudo fdisk –l i fixar-se dels discs que tenim al nostre sistema. En mac diskutil list
- 2. Inserir la microSD directament o amb algun acoplador. Es recomana a un port USB 3.
- 3. Tornem a executar sudo fdisk –l . Fixar-se en el tamnay (8 o 16GB). Serà algun disk que no teniem al pas 1. Suposarem que s'ha muntat en /dev/sdx .
- 4. En cas que linux l'haja muntada en algun lloc, haurem de desmuntar-la sudo umount /dev/sdx. Pot-ser bote algun error que el disc no està muntat; no passa res, és el que voliem
- 5. I finalment, a la carpeta on tenim el fitxer: (if i of són input/output file)

sudo dd bs=16M if=arxiu.img of=/dev/sdx

Configuració comuna(1)

Totes les raspberrys que formen part del clúster han de tindre una configuració comuna:

- 1. Arrancar una raspberry (la 1) amb monitor i teclat connectat. Tindrà xarxa per DHCP.
- 2. sudo apt update , sudo apt upgrade
- 3. Executem sudo raspi-config i passar per les següents parts:
 - i. Menú 1 System Options:
 - S4 Hostname → node1
- 4. Menú 2 Display Option : Ací no tocarem res
- 5. Menú 3 Interface Options:
 - P2 SSH i habilitarem el login remot i el servidor SSH
- 6. Menú 4 Performance Options:
 - i. P2 GPU Memory i en deixem sols 16MB. Pensa que sols entrarem en la consola

Configuració comuna (2)

- 5. Menú 5 Localization:
 - i. L1 Locale: llevarem en_GB.UTF8 i posarem el es_ES.ETUF-8
 - ii. L2 Timezone : posarem Europe -> Madrid
 - iii. L3 Keyboard : seleccionarem Spanish
- 6. Menú 6 Advanced Options:
 - i. A1 Expand Filesystem -> per ocupar tota la sd
 - ii. A4 Network Interface Names -> seleccionem no . Per tenir eth0 en compte de enxb827eb9f90a4 (unac combinació del literal enx seguit de la MAC de la interfícies)
- 7. Menú 8 Update no cal res, ja que hem fet el update-upgrade abans
- 8. Menú 9 About no cal res
- 9. sudo reboot

Configuració comuna. Instalar MPI (1)

- 1. mkdir mpich3 La carpeta que contindrà l'instalador
- 2. cd mpich3 Entrem i descarreguem la versió
- 3. wget http://www.mpich.org/static/downloads/3.3.2/mpich-3.3.2.tar.gz
- 4. Descomprimim: tar xfz mpich-3.3.2.tar.gz
- 5. sudo mkdir /home/rpimpi
- 6. sudo mkdir /home/rpimpi/mpi-install
- 7. sudo mkdir /home/pi/mpi-build
- 8. cd /home/pi/mpi-build
- 9. sudo apt-get install gfortran

Configuració comuna. Instalar MPI (2)

Compilem MPI per a la plataforma. Aquest procés pot durar fins 1 hora

- 1. sudo /home/pi/mpich3/mpich-3.2.2/configure -prefix=/home/rpimpi/mpiinstall
- 2. sudo make → compilem
- 3. sudo make install → instalem
- 4. afegim mpi al path: nano .bashrc en l'ultima linia PATH=\$PATH:/home/rpimpi/mpi-install/bin
- 5. reiniciar → sudo reboot
- 6. Comprovar que mpi funciona: mpiexec -n 1 hostname

Configuració comuna. Instalar MPI (3)

Instalem les llibreries de per a programar en Pytohn

- 1. Instal·lar les llibreries extra de python sudo apt install python-dev
- 2. Instal·lar el gestor de llibreries → sudo apt install python-pip
- 3. Instal·lar mpi4py → pip install mpi4py
- 4. Provem que funciona → mpiexec -n 4 python helloworld.py

```
# -*- coding: utf-8 -*-
from mpi4py import MPI
import sys

size=MPI.COMM_WORLD.Get_size()
rank=MPI.COMM_WORLD.Get_rank()
name=MPI.Get_processor_name()

print("Hello world, Soc el procés %2d de %2d al node %10s" %(rank,size,name))
```

Clonació de la targeta SD.

En aquets apartat el que haurem de fer és :

- 1. Apagar la Raspberry
- 2. Fer un fitxer **img** a partir de la microSD.
- 3. A partir del nou img gravar les altres 3 targetes.

Es subministra un fitxer img creat amb tota la instal·lació ja creada. Per tant la primera part de configuració **no caldrà fer-la**.

En aquest moments és com si tinguerem 4 màquines idèntiques. Haurem de fer alguna cosa per fer-les disitntes

Configuración de cada node per separat

Hem de configurar en cada node:

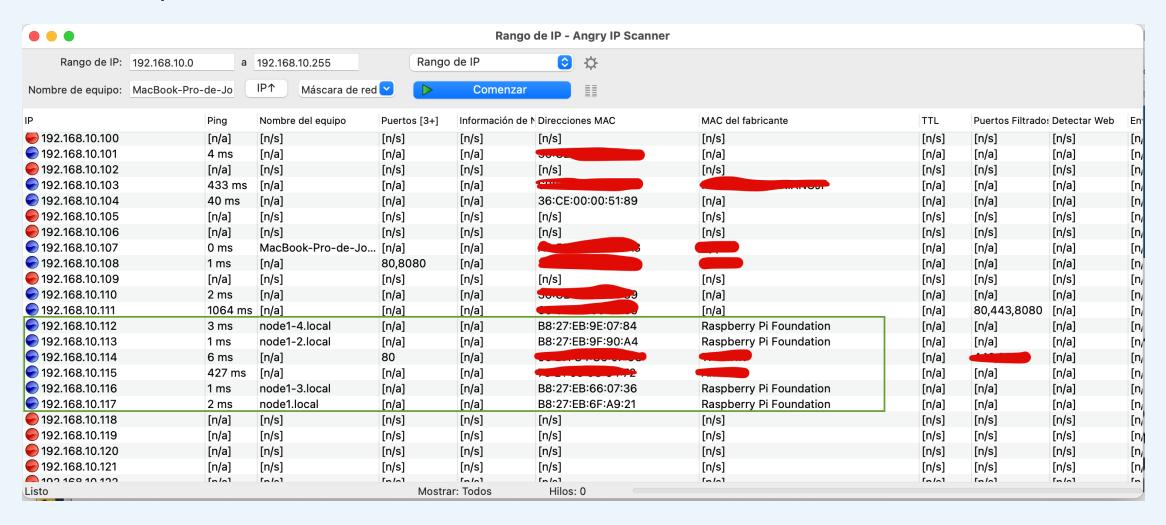
- 1. Adreça estàtica
- 2. Hostname
- 3. Crear clau ssh
- 4. Transferir la clau entre tots els nodes
- 5. Muntar una carpeta compartida amb *nfs*

Notes:

- Necessitarem un *sniffer* de la xarxa per descobrir quines IP's tenen. Es recomana https://angryip.org.
- Per treballar amb totes les màquines alhora, podem fer servir alguna implementació de *cluster-ssh*

Configuración de cada node (1)

Descobrir quines adreces IP tenen cadascun dels nodes.



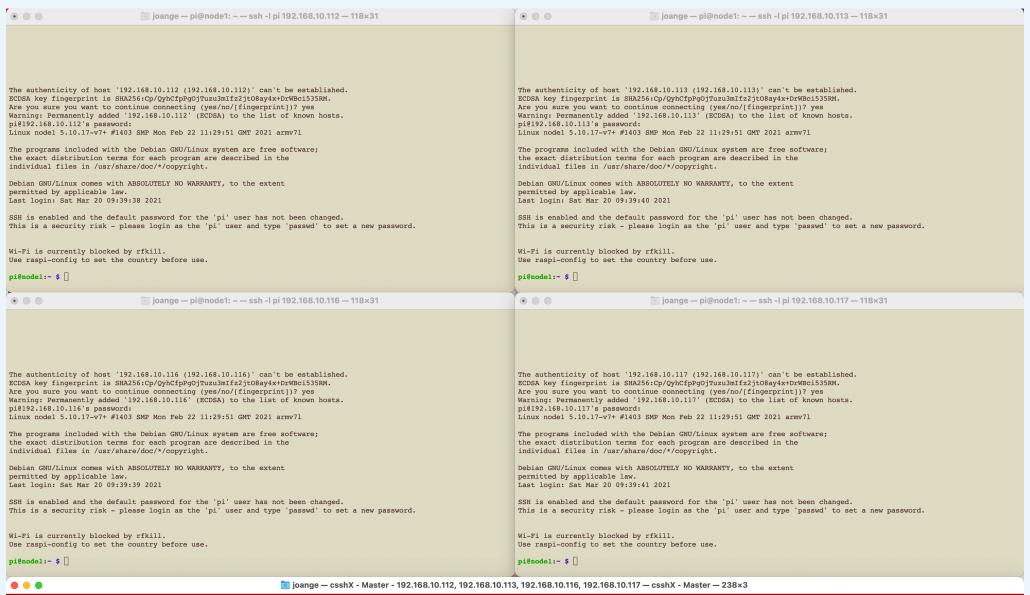
Configuración de cada node (2)

Amb alguna ferramenta com cluster-ssh ens connectem a elles

```
MacBook-Pro-de-Joan:~ joange$ cat clusterPI
192.168.10.112
192.168.10.113
192.168.10.116
192.168.10.117
MacBook-Pro-de-Joan:~ joange$ csshX --login pi --host clusterPI
```

- Hem de crear un fitxer de text amb les IP's que hem trobat anteriorment (clusterPI a l'exemple)
- Haurem de escrure un yes per acceptar el fingerprint
- Escriure el password raspberry

Configuración de cada node (3)



Configuración de cada node (4)

Adreça estàtica - /etc/network/interafaces

```
# source-directory /etc/network/interfaces.d

auto eth0
#iface eth0 inet dhcp
iface eth0 inet static
address 192.168.10.5x
netmask 255.255.255.0
gateway 192.168.10.1
```

Notes:

- La primera linia la comentarem, així com afegirem una comentada per dhcp
- la x serà del 1..4. Desprès segons el valor de x li donarem nom al hostame
- canviar 192.168.10 per la xarxa de l'aula adequada
- Atenció: com muntarem dos clústers, un que comencé en la 50 i altre en la 60.

Configuración de cada node (5)

Nom del host - /etc/hostname

Per a identificar cada màquina dins de cada clúster i en tota l'aula, li posarem com a nom node_X_Y on:

- X serà el número de clúster
- Y serà el número de node dins del clúster.

Dins de cada fitxer /etc/hostname contindrà el seu nom de host.

Configuración de cada node (6)

Equips del clúster - /etc/hosts

Aquest fitxer conté el llistat de tots els nodes del clúster, amb el seu nom i la seua IP. Això ens servirà per fer servir noms en compte d'adreces IP.

```
127.0.0.1
                localhost
                localhost ip6-localhost ip6-loopback
::1
                ip6-allnodes
ff02::1
ff02::2
                ip6-allrouters
192.168.10.51
                node_1_1
192.168.10.52
                node 1 2
192.168.10.53
                node 1 3
                node_1 4
192.168.10.54
```

Reiniciar tot el cluster i fer proves de ping. Hauras de netejar el teu fitxer de hoss conegut del ordinador des d'on ens connectem, ja que hem canviat la IP ~/.ssh/known_hosts

Primera prova d'execució (1)

Anem a treballar sols amb el node1

- 1. Crec carpeta mpi_test: mkdir mpi_test
- 2. Moure o crear amb editor nano el programa d'abans: mv helloworldmpi.py mpi_test/
- 3. Entrem i crear el següent machinefile. Aquest fitxer conte una linia per cada node del cluster, amb la sintaxi node [: cores]

```
node_1_1:4
node_1_2:4
node_1_3:4
node_1_4:4
```

El numeret desprès dels dos punts indica els nuclis d'execució que supporta cada node.

Primera prova d'execució (2)

```
pi@node1:~/mpi_test $ mpiexec -f machinefile -n 4 python helloworldmpi.py
Hello world, I'm process 0 of 4 in processor node_1_1
Hello world, I'm process 1 of 4 in processor node_1_1
Hello world, I'm process 2 of 4 in processor node_1_1
Hello world, I'm process 3 of 4 in processor node_1_1
```

Tot be, ja que cada node té 4 cores, i s'executa tot en el node1. Però que passa si fem:

```
pi@node1:~/mpi_test $ mpiexec -f machinefile -n 16 python helloworldmpi.py
Host key verification failed.
Host key verification failed.
Host key verification failed.
```

Falla. No tenim accès a la resta de nodes a mitjançant la xarxa. MPI es comunica per ssh . Anem a solucionar-ho.

Configuración de cada node (7)

- 1. Hem d'aconseguir poder fer login automàticament desde qualssevol node a qualssevol altre node.
- 2. Per aixó farem en node_1_x (x=1..4)

Exportem en tots els nodes les claus dels altres tres. Exemple de importació de la clau de node_1_1 als altres tres:

```
scp node_1_1:/home/pi/.ssh/node_1_1_key . # vigila el últim .
cat node_1_1_key>>authorized_keys
```

El comandament transfereix la clau pública del node 1 a la màquina des d'on ho hem executat.

Configuración de cada node (8)



En authorized_keys tenim les claus ssh dels altres tres nodes. Ja podem entrar (login) sense problema

Primera prova d'execució (3)

Tornem al prova, des del node_1_1

```
pi@node1:~/mpi_test $ mpiexec -f machinefile -n 16 python helloworldmpi.py
[proxy:0:3@node_1_4] launch_procs ... /home/pi/mpi_test (No such file or directory)
```

Altre Error !!! El que indica el següent missatge és que quan estavem en node_1_4 (o altre node del clúster), ha intentat entrar en la carpeta /home/pi/mpi_test i no la troba.

Problema → El codi font ha d'estar en la mateixa ruta en tots els nodes

Possibles solucions:

- Cada cop que editem el codi, l'haurem de copiar en totes els nodes. Implica copiar-ho per a cada modificació
- Creem una carpeta en xarxa, compartida per tots els nodes per NFS. Aquesta és la bona 👍

Configuración de cada node (9)

La manera de treball serà:

node_1_1:

- Executarà un servidor de nfs , i exportarem (compartirem) una carpeta per xarxa
- Com a programadors treballarem exclusivament en aquest node.

resta de nodes:

- Monterem durant l'arranc la carpeta en xarxa que existeix en node_1_1
- Estaran en funcionament, però no treballarema amb ells. Seràn invocats per node_1_1 al moment d'executar algun programa.

Configuración de cada node (10)

Instalar servidor nfs i compartir carpeta - (en node_1_1)

- sudo apt install nfs-kernel-server
- mkdir /home/pi/cloud
- sudo nano /etc/exports i afegir la següent linia

```
/home/pi/cloud *(rw,sync,no_root_squash,no_subtree_check)
```

- sudo chmod -R 777 /home/pi/cloud
- sudo update-rc.d rpcbind enable
- sudo service rpcbind restart
- sudo exportfs -a
- sudo service nfs-kernel-server restart

Configuración de cada node (11)

Instalar client nfs i montar carpeta - (en node_1_x, x=2,3,4)

- sudo mkdir /home/pi/cloud
- sudo /etc/fstab i afegir la linia:

```
node1:/home/pi/cloud /home/pi/cloud nfs auto,noatime,nolock,bg,nfsvers=4,intr,actimeo=1800 0 0`
```

Reiniciem en tots els node_1_x per comprovar que ho automonta

```
pi@node4:~/cloud $ df -h
S.ficheros
                    Tama?o Usados
                                   Disp Uso% Montado en
/dev/root
                       14G
                             1,8G
                                    12G 13% /
devtmpfs
                      455M
                                0 455M
                                          0% /dev
tmpfs
                      487M
                                   487M
                                          0% /dev/shm
tmpfs
                      487M
                              13M 475M
                                          3% /run
tmpfs
                       5,0M
                             4,0K 5,0M 1% /run/lock
tmpfs
                                0 487M
                                          0% /sys/fs/cgroup
                       487M
/dev/mmcblk0p1
                      253M
                              49M 204M
                                         20% /boot
node1:/home/pi/cloud
                                        13% /home/pi/cloud
                             1,8G
                                    12G
                       14G
                                          0% /run/user/1000
                                    98M
tmpfs
                        98M
```

Primera prova d'execució (4)

• En node_1_1 movem el programa helloworldmpi.py i el machinefile de mpi_test a cloud, que serà ja la carpeta de treball.

```
pi@node1:~/cloud $ mpiexec -f machinefile -n 16 python helloworldmpi.py
Hello world, Soc el procés 0 de 16 a
                                         node1
Hello world, Soc el procés 8 de 16 a
                                         node3
Hello world, Soc el procés 12 de 16 a node4
Hello world, Soc el procés 4 de 16 a
                                         node2
Hello world, Soc el procés 1 de 16 a node1
Hello world, Soc el procés 9 de 16 a
                                         node3
Hello world, Soc el procés 13 de 16 a
                                         node4
Hello world, Soc el procés 5 de 16 a
                                         node2
Hello world, Soc el procés 2 de 16 a
                                         node1
Hello world, Soc el procés 10 de 16 a
                                         node3
Hello world, Soc el procés 14 de 16 a
                                         node4
Hello world, Soc el procés 6 de 16 a
                                         node2
Hello world, Soc el procés 3 de 16 a
                                         node1
Hello world, Soc el procés 11 de 16 a
                                         node3
Hello world, Soc el procés 15 de 16 a
                                         node4
Hello world, Soc el procés 7 de 16 a
                                         node2
```

Primera prova d'execució (i 5)

Observem que:

- S'han executat 4 tasques en cada node, gràcies a la configuració del machinefile (recordes node_1_1:4 ?)
- El funcionament és anàrquic: molts processos fent coses alhora, i no hi ha control del que ix alhora
- Fes distintes proves en múltiples de 4

Fi de la primera part

Fi de la primera part

Tornem i a programar...